Qwen3.6-35B-A3B 多专家 LoRA 训练与模型合版

摘要　以 Qwen3.6-35B-A3B 为基座，为四个评测各训练一个 LoRA 专家（每个约一千五百万词元），在稠密权重空间用 TIES 合成最终模型，并与用数据并集训练的单个 LoRA 对照。最终模型相对实测基座的四项宏平均变化为 −3.2 个百分点（95% 置信区间 −5.8 至 −0.7），没有达到提升三个百分点的目标，但显著优于混合训练对照（宏平均高 4.2 个百分点）。专家本身收益有限，合版又带来空补丁、轨迹变长和思考截断等行为回退。部分失败来自评测框架，均已单独标注。

过程

- **数据**：每个专家的训练集都是自建的，只用开源权重教师和宽松许可证数据，按 token 对齐（约 15M）。剔除 11 个 HARD-51 仓库、与 TB2 重合的任务和全部 HLE 衍生数据，并做 13-gram 与 embedding 去污染。评测的题目、答案和测试不用于训练或选模型。
- **训练**：LoRA r=32（单卡即可训练，adapter 153MB，便于在 ΔW 空间合版；bf16 基座单张 H200 放得下，不需要 QLoRA），适配注意力、Gated DeltaNet 和 shared expert（250 个模块，3830 万参数），routed experts 和 router 不动；lr 1e-4，2 epoch。7 次训练共 12.3 GPU 小时。v1 专家测试表现不佳后，换数据重训了 E-SWE v2 和 E-TB v2；后者同时修正了训练与推理时 thinking 格式不一致的问题。
- **合版**：TIES（每个模块保留幅值前 50%，符号投票后只对同号专家取平均，λ=1），超参由独立开发集的 val loss 从 18 个 Linear/TIES/DARE 候选中选出。最终模型 v4 = E-SWE v2 + E-TB v2 + E-ASI + E-HLE，定稿时还没有任何 v3/v4 的测试分数。
- **对照与评测**：Mixed 是用专家数据并集、相同超参训练的单个 LoRA。四项 benchmark 版本锁定，vLLM 配置相同。Base 和 v4 跑全部四项（SWE 各 3 次，TB2 见下），专家只测目标 benchmark，Mixed 四项各 1 次。

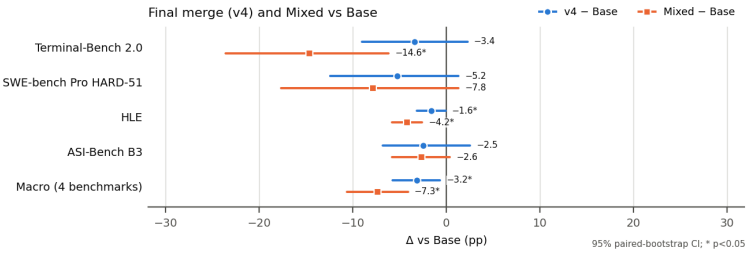
结果

主指标为百分制，环境失败计 0 分；括号内为配对 bootstrap 的 95% CI；“—”表示不在评测范围内。TB2 为同一台 8×H100 Docker 节点上的运行（Base 2 次、其余各 1 次）。

	Base	E-SWE v2	E-TB v2	E-ASI	E-HLE	Mixed	v4	Δ v4−Base
SWE HARD-51（3 次均值）	21.6	27.5	—	—	—	13.7	16.3	−5.2（−12.4, +1.3）
TB2	44.9	—	38.2	—	—	30.3	41.6	−3.4（−9.0, +2.3）
HLE（n=2500）	20.8	—	—	—	16.9	16.6	19.2	−1.6（−3.2, −0.1）
ASI-Bench B3	10.0	—	—	7.8	—	7.4	7.5	−2.5（−6.8, +2.5）
宏平均	24.3					17.0	**21.2**	**−3.2（−5.8, −0.7）**

v4 相对 Mixed：TB2 +11.2（+3.4, +20.2），HLE +2.6（+1.1, +4.2），宏平均 +4.2（+1.1, +7.3）。算力：集群 108.9 GPU 小时（训练 12.3、评测 93.3），另租 RunPod 2×H200 两台（ASI）和 Nebius 8×H100 一台（TB2，71.9 GPU 小时）；实际支出 564 美元（Nebius 325、RunPod 190、判分 API 49）。

运行失败率 %（环境失败 / 超时）	SWE	TB2	HLE	ASI
Base	0 / 0	5.1 / 19.1	0.1 / 0.2	1.7 / 0
目标专家	0 / 25.5	0 / 25.8	0.2 / 0.1	3.3 / 0
Mixed	0 / 0	0 / 14.6	0.2 / 0.2	3.3 / 0
v4	0 / 3.3	0 / 29.2	1.6 / 0.2	1.7 / 0



主要发现

1. **合版没有超过基座，但优于混合训练**：v4 四项都低于 Base（只有 HLE 显著），宏平均 −3.2。它显著优于 Mixed（宏平均 +4.2），也比不含 E-TB v2 的 v3 在 HLE 上高 1.9（p=0.02）。
2. **专家本身收益有限**：E-SWE v2 在 SWE 上 +5.9、E-TB v2 在 TB2 上 −6.7（均不显著），E-HLE 和 E-ASI 在各自 benchmark 上低于 Base；E-TB v1 在集群 TB2 上显著退步（24.7 vs 集群 Base 41.6，Δ −16.9，CI −26.4 至 −7.9），已剔除。小规模 agent 微调更容易学到教师的风格，而不是验证能力。
3. **合版引入的行为回退**（失败案例 46 个，其中 42 个在 v4 上、12 个为合版引入）：SWE 中 v4 有 12 个 trial 先 commit 再提交，其中 11 个补丁为空；TB2 中 v4 的步数中位数约为 Base 的 2 倍，超时率 29% 对 19%；HLE 中 40 题没有给出答案（多为思考写满上限）；E-HLE 的校准改进（校准误差 74→36）合版后只保留约四分之一（64）。
4. **评测框架失败**：prompt 加 80K max_tokens 超过 256K 后，Terminus-2 的摘要回退陷入死循环，直到 3 小时超时；SWE 补丁末尾换行被去掉，导致最后一个文件被丢弃（已全部重新判分）。所有模型同样受影响。

局限：剔除 E-TB v1、重训 v2 专家都是看过测试结果之后的迭代，SWE 和 TB2 的 Δ 可能偏乐观。专家和 Mixed 只跑 1 次，Mixed 用的是 v1 数据；TB2 没有达到 5 次。ASI 是 seed31415 的本地评分（2 题需要 Docker 的评分器记为环境失败），agent 阶段在租用节点上没有沙箱隔离（agent 曾用 pkill 杀掉评测进程，受影响的题已重跑）；TB2 的同条件比较用 Docker，集群上的运行用 apptainer。

链接：代码、逐任务结果和置信区间见 https://github.com/eh3323/qwen36-moe-merge（README §8–§11），失败案例见 `analysis/failure_cases.md`，模型见 Hugging Face：merged-v4、lora-experts。